



Pontifícia Universidade Católica de Campinas · Engenharia de Software
Estudos Avançados de Banco de Dados · Prof. José Guilherme Picolo

Análise da Aviação Civil Brasileira

Dashboard Interativo dos Voos da ANAC (VRA 2024)

Felipe Cosmo Granziol · Guilherme Bars · Gustavo Kurten
João Celso · Pedro Tiezo Sales Shimizu

Campinas · 2026

Tema e pergunta de pesquisa

- › A aviação comercial é um **termômetro da economia e da mobilidade** do país.
- › Analisamos os dados abertos da **ANAC (Voo Regular Ativo, VRA)**, de todo o ano de 2024.

Pergunta que guia o estudo: quem voa no Brasil, quando voa e **onde estão os gargalos de pontualidade** da aviação comercial?

~988 mil

voos regulares

110

companhias

385

aeroportos

12 meses


ano de 2024

Fonte dos dados: 3 fontes públicas integradas

Fonte	Arquivos	Papel no modelo	Registros
VRA (ANAC) sistemas.anac.gov.br	12 CSV mensais	Tabela-fato (cada voo)	~988 mil
OurAirports	airports.csv	Dimensão de aeroportos (cidade, UF, região, lat/lon)	~80 mil
Companhias ANAC / OpenFlights	dim_companhias.csv	Dimensão de companhias (nome, país, grupo)	62

Requisitos atendidos: ≥ 10.000 registros (um único mês já tem ~85 mil voos) e ≥ 2 arquivos distintos, com forte potencial de análise comparativa.

Pipeline de Ciência de Dados



Cada etapa exigida no projeto, implementada em **Python + Pandas** · scripts em `src/`.

Aquisição de dados

- › Leitura dos **12 CSV mensais** do VRA com Pandas (sep=";", pulando a linha de metadado "Atualizado em:").
- › Cada arquivo traz ~85 mil voos com horários previsto/real, origem, destino e situação.
- › **BÔNUS:** um **crawler** (src/crawler.py) baixa sozinho os 12 meses + aeroportos, direto da ANAC, sem login.

```
# aquisição + empilhamento dos meses
partes = [pd.read_csv(arq, sep=";", skiprows=1) for arq in glob("data/raw/VRA_*.csv")]
voos = pd.concat(partes)           # 988.022 voos
```

Integração de dados: concat + merge

- › **Concatenação (concat):** empilha os 12 meses em uma única base de ~988 mil linhas.
- › **Merge 1 e 2:** voos × **aeroportos** (na origem e no destino) → cidade, UF, região e coordenadas.
- › **Merge 3:** voos × **companhias** → nome, país e grupo da empresa.

Resultado: cada voo passa a carregar a **geografia** de origem/destino e a **identidade da companhia**, e a base fica pronta para comparar grupos.

Limpeza e tratamento dos dados

Valores ausentes

Coluna Código Justificativa estava **100% vazia** → removida. Voos realizados sem horário previsto → mantidos usando a **partida real** como referência.

Inconsistências

Atrasos absurdos (> 12 h, erro de fuso) → tratados como nulos. **Duplicatas** removidas. Período restrito a 2024.

Padronização

Datas → datetime ISO8601 (corrige segundos fracionados que falhavam).
Códigos ICAO em maiúsculo; situação do voo uniformizada.

Preparação para análise: base consistente, sem ambiguidade de formato, pronta para a etapa de transformação.


Transformação de dados: novas variáveis

- › **Padronização:** textos, categorias e unidades de tempo (minutos).
- › **Criação de variáveis:** atraso_chegada_min, atrasado (> 15 min), cancelado, rota, distancia_km (fórmula de **Haversine**), recortes temporais (mês, dia da semana, hora, período).
- › **Agregações:** por companhia, rota, aeroporto, mês e dia x hora.

Base final: 46 colunas, limpa e enriquecida, salva em data/processed/voos.parquet.

Análise exploratória


- › Estatística descritiva + gráficos (**matplotlib / seaborn**).
- › **16,9%** dos voos atrasam > 15 min; **4,3%** são cancelados.
- › Na mediana, os voos chegam **~3 min adiantados**, mas a cauda de atrasos é longa.
- › A análise revelou **6 insights interpretados** →



Um mercado de três gigantes



- **O que encontramos:** Azul (40%), LATAM (30%) e Gol (25%) concentram **~95% do mercado doméstico**.
- A **Azul é a maior**, mas a **menos pontual** das três (16,7% vs ~14,5%).

Por que importa: é um **oligopólio**, e a líder paga o preço de voar muitos aeroportos regionais, mais sujeitos a atraso.



Os atrasos se acumulam ao longo do dia


- **O que encontramos:** a taxa de atraso sobe de **~8% pela manhã** para **~22% no fim de tarde/noite**. É o clássico **efeito cascata** (um atraso cedo se propaga). Pior janela: **quinta e sexta à noite**.



Sazonalidade do volume e dos cancelamentos

- **O que encontramos:** volume com **picos em julho** (férias) e no fim de ano; vale em fevereiro.
- Cancelamentos mais altos no **início do ano** (jan ~5%).


Por que importa: o calendário (férias e chuvas de verão no Sudeste) explica picos de demanda e de cancelamento, o que ajuda a planejar capacidade.



Internacionais atrasam mais que domésticos



- › **O que encontramos:** **22,5%** dos voos internacionais atrasam, contra **15,8%** dos domésticos.

Por que importa: rotas longas, congestionamento nos grandes hubs e procedimentos de imigração/alfândega ampliam o atraso acumulado na chegada.





O Brasil voa pelo Sudeste

- › **O que encontramos:** São Paulo (Guarulhos + Congonhas), Brasília, Rio e Belo Horizonte concentram a maior parte do movimento. **Poucos hubs** respondem pela maioria dos voos, o que torna a malha vulnerável a gargalos nesses aeroportos.



Os dois dashboards (Dash + Plotly)

- **Dashboard 1, Visão Geral:** indicadores-chave + 4 gráficos sintéticos (painel executivo).
- **Dashboard 2, Exploração Interativa:** 4 filtros + 7 visualizações de tipos diferentes (linha, barras, heatmap, dispersão, pizza e mapa).



O que os dados nos contam

- › Aviação brasileira **concentrada**: três empresas e o eixo Sudeste dominam.
- › Pontualidade **previsível**: piora ao longo do dia e no fim de semana (efeito cascata).
- › Perfis de operação distintos: a líder **Azul** troca pontualidade por **capilaridade regional**.
- › ~1 milhão de linhas de dados crus → **informação útil** para o passageiro e para o setor.

Repositório completo (código + dados + relatório):

github.com/GuilhermeBars/dashboard-aviacao-anac